

# RESEÑA: GEOMETRIC LEARNING OF KNOT TOPOLOGY

Juan José H. Beltrán

## 1. INTRODUCCIÓN

Los nudos han sido objeto de estudio de la humanidad desde miles de años atrás. Pues, si bien su estudio formal matemático se desarrolló y estructuró durante el siglo XIX, existen registros mucho más antiguos de nuestro interés por ellos, como los nudos celtas y los quipus de las civilizaciones andinas, solo por mencionar algunos (Van de Griend, 1996). Esta necesidad de entenderlos mejor llevó a Peter Guthrie Tait a realizar a mano la primera tabla de nudos matemáticos (curvas cerradas) para su clasificación en 1885, contando con nudos de hasta diez *crossings*. Hoy en día se han clasificado más de un millón de nudos distintos, de hasta 16 *crossings*, de forma computacional. Todos estos esfuerzos se ven justificados por la amplia variedad de aplicaciones que tiene la teoría de nudos en otras áreas como física, química y biología, por mencionar algunas.

Dos nudos se dicen equivalentes si uno puede transformarse en el otro a través de una isotopía del ambiente, es decir, "sin hacer cortes". Uno de los problemas abiertos más relevantes relacionados a nudos es encontrar *knot invariants* que permitan saber de forma rigurosa y eficiente si dos nudos son o no equivalentes. Por ello se han desarrollado *knot polynomials*, por ejemplo, que resultan invariantes ante deformaciones en la curva que preservan su topología. Sin embargo, existen nudos que no pueden ser distinguidos a través de *knot polynomials* u otros invariantes. A la par, determinar la topología subyacente de una curva utilizando únicamente información geométrica de sus segmentos, es decir, sin invariantes algebraicos, es también un problema abierto.

En este marco, el artículo GEOMETRIC LEARNING OF KNOT TOPOLOGY (Sleiman et al., 2024), de Joseph Lahoud Sleiman et. al. propone el "*local writhe*", una representación geométrica para nudos, como una alternativa a los *knot invariants* estándar. Esto se lleva a la práctica a través de aprendizaje geométrico, utilizando el *writhe* de los nudos para entrenar redes neuronales *feedforward* y recurrentes que permiten distinguir curvas de hasta 11 *crossings* que resultan problemáticas para los *knot invariants* tradicionales. Muestran también que esta metodología es

escalable para clasificar los 250 nudos primos de hasta 10 *crossings* con 95 % de exactitud, e incluso que puede utilizarse para resolver problemas de *knot localisation*.

## 2. REVISIÓN DEL ARTÍCULO

Trabajos previos, como Vandans et al., 2020, posicionaron al machine learning como una técnica prometedora para resolver problemas de clasificación de nudos. En ellos, la información de los nudos se representa utilizando principalmente coordenadas cartesianas, distancias, y ángulos diedros. En cambio, el artículo que aquí se analiza propone otra representación llamada *local writhe*.

**2.1. Local Writhe.** Esta característica se basa en la *linking integral* de Gauss, cuyo resultado, el *linking number*, representa intuitivamente "la cantidad de veces que las curvas se envuelven alrededor de la otra". De esta forma, aplicar la *linking integral* sobre una única curva puede asociarse con qué tan enredada (en inglés "*writhe*") está la curva consigo misma. Con esto en mente se definen las siguientes características de una curva:

**2.1.1. Local segment-to-segment (StS) writhe.** Partiendo una curva cerrada en una cantidad finita de segmentos (en la práctica), para cada par, esta cantidad representa la magnitud y la quiralidad del enredo entre ambos segmentos. Se define formalmente como:

$$\omega_{StS}(x, y) = \frac{(t(x) \times t(y)) \cdot (r(x) - r(y))}{\|r(x) - r(y)\|^3},$$

donde  $r(x)$  y  $t(x)$  son las posiciones en tres dimensiones del segmento  $x$  y de la tangente a éste, respectivamente.

**2.1.2. Local segment-to-all (StA) writhe.** Integrando todos los *StS writhe* de un segmento con cada diferencial de la curva completa, se representa "qué tan enredado está un segmento determinado, respecto a toda la curva cerrada". Esta cantidad se define como:

$$\omega_{StA}(x) = \oint_y \omega_{StS}(x, y) dy,$$

donde  $x$  es un segmento de una curva cerrada  $y$ .

De esta forma, para una determinada curva cerrada, su representación a través de  $\omega_{StA}$  se codifica en un arreglo unidimensional tal que el  $i$ -ésimo elemento corresponde al  $\omega_{StA}$  del  $i$ -ésimo segmento. Análogamente, la representación a través de  $\omega_{StS}$  se codifica en una matriz cuadrada tal que el  $(i, j)$ -ésimo elemento corresponde al  $\omega_{StS}$  del  $i$ -ésimo y  $j$ -ésimo segmentos.

En la práctica, estas características se calculan utilizando segmentos discretos, determinados tomando ventanas lo suficientemente grandes para evitar fluctuaciones a pequeña escala.

**2.2. Redes Neuronales para Aprendizaje Geométrico.** La hipótesis es que  $\omega_{StA}$  es una representación geométrica que forma patrones asociados con la topología subyacente de la curva. Por lo tanto, ya que el reconocimiento de patrones complejos es una tarea típicamente abordada con machine learning, se propone que una red neuronal entrenada para reconocer los patrones de  $\omega_{StA}$  será capaz de clasificar nudos exitosamente. Alternativamente, también se hicieron algunas pruebas entrenando los modelos con los datos de  $\omega_{StS}$ .

**2.2.1. Representación y Generación de Datos.** Las curvas cerradas se modelaron como *bead-spring polymers* con  $N = 100$  beads. En este modelo los beads se unen a través de *springs* para representar un polímero o, en este caso, una curva cerrada. Para entrenar los modelos, se generaron  $10^5$  ejemplos sin correlación para cada tipo de nudo utilizando *KnotPlot*, luego, se evolucionaron utilizando *LAMMPS* de forma que su topología se preservara.

**2.2.2. Arquitectura.** Se utilizaron dos arquitecturas: *feedforward* (FFNN) y recurrente (RNN). Esta última arquitectura se requirió especialmente para resolver problemas de *knot localisation*. Se utilizó *sparse categorical cross-entropy* como función de pérdida. La capa de entrada de cada red neuronal se adaptó para ajustarse a la representación que deseaba estudiarse. La cantidad de capas ocultas (generalmente 4), unidades, *learning rate* y *batch size* se determinó con un ajuste automático de hiperparámetros. La capa de salida se conforma por una neurona por tipo de nudo a clasificar, cada una de ellas con una función de activación *softmax*. De esta forma, cada neurona de la capa de salida retorna una probabilidad de que la entrada corresponda a determinado tipo de nudo.

**2.3. Resultados.** Se realizaron pruebas entrenando redes neuronales con diferentes características de las curvas, incluyendo: coordenadas cartesianas XYZ, curvatura local, densidad, *1D writhe* (Sleiman et al., 2022), además de  $\omega_{StA}$  con y sin signo.

**2.3.1. *StA Writhe vs Características Cartesianas.*** Ninguna de las características cartesianas (curvatura local, densidad y *1D writhe*) logró superar el desempeño de la representación XYZ. Sin embargo, los modelos entrenados con  $\omega_{StA}$  lograron hasta un 99% de exactitud en su clasificación. Esto prueba que el local writhe es un predictor muy prometedor para este problema.

**2.3.2. *StA Writhe vs Knot Polynomials.*** Para poner a prueba el desempeño de las redes neuronales entrenadas con  $\omega_{StA}$  frente a casos en los que los *knot polynomials* tienen problemas, se consideraron tres nudos con polinomios de Alexander idénticos: the *square*, *granny*, y  $8_{20}$ . Nuevamente, los resultados fueron muy positivos para los modelos entrenados con  $\omega_{StA}$ , obteniendo una exactitud del 99.98%; frente al 91.8% de los modelos entrenados con coordenadas XYZ.

Se realizó una segunda prueba con nudos más complejos que comparten polinomios de Alexander y Conway: el nudo Conway ( $K11n34$ ), el nudo de Kinoshita-Terasaka (KT,  $K11n42$ ) y el nudo trivial. Siguiendo la misma metodología, las redes neuronales entrenadas con coordenadas XYZ fueron incapaces de distinguir entre los nudos de Conway y KT. Por su parte, las redes entrenadas con  $\omega_{StA}$  lograron distinguir entre los tres nudos con una exactitud del 99.6%.

A partir de estos experimentos, los autores concluyen que las redes neuronales entrenadas con  $\omega_{StA}$  tienen la capacidad de asociar los patrones del *local writhe* con la topología de los nudos.

Personalmente, me habría gustado más pruebas en este apartado. Así como las redes neuronales entrenadas con coordenadas XYZ lograron clasificar correctamente el primer caso de prueba pero fallaron rotundamente en el segundo, me cuesta simplemente descartar la posibilidad de que esto pueda ocurrir también para las redes neuronales entrenadas con  $\omega_{StA}$  en otros casos. Aunque en la siguiente sección se incluyen también algunos nudos que comparten *knot polynomials*, estos ya no se estudian particularmente.

**2.3.3. *StA vs StS en Casos Grandes.*** Para probar la eficacia de este acercamiento al clasificar nudos más complejos, se generaron conjuntos de entrenamiento incluyendo todos los nudos primos de hasta 10 *crossings*. De esos 250 nudos, 20 comparten el mismo polinomio de Alexander, volviéndolos difíciles de clasificar utilizando herramientas tradicionales.

En este caso, al probar clasificando nudos de hasta 7 *crossings*, las redes neuronales entrenadas con coordenadas XYZ rápidamente redujeron su exactitud a medida que crecía la cantidad de *crossings* (ver Figura 1-B). Por su parte, las redes neuronales entrenadas con  $\omega_{StA}$  obtuvieron altos niveles de exactitud.

Sin embargo, en la matriz de confusión se observaron problemas para clasificar los nudos  $5_1$  y  $7_2$  (ver Figura 1-D), pues estos generan patrones  $\omega_{StA}$  similares (ver Figura 1-C).

Se teoriza que esto ocurre porque al integrar los valores StS para formar el StA, algunos StS con signos distintos pueden contrarrestarse y, una vez integrados en la dirección del contorno, dos nudos de distinta topología pueden producir patrones similares. Para solucionar este problema, se decidió entrenar la red neuronal con los valores  $\omega_{StS}$  de los nudos (ver

Figura 1-E). Esto tuvo muy buenos resultados, solucionando esta confusión y permitiendo escalar hasta clasificar los 250 nudos primos de hasta 10 *crossings*, obteniendo aún una exactitud del 95 % (ver Figura 1-F).

De este experimento se concluye que el mejor predictor para escalar el problema es  $\omega_{StS}$  (ver Figura 1-G). Dada la naturaleza matricial de esta característica, surge la idea de utilizar redes neuronales convolucionales en un trabajo futuro, pues esta arquitectura podría mejorar la capacidad del modelo para distinguir entre nudos más complejos sin perder exactitud.




FIGURA 1. Resultados clasificando nudos de 7 o más *crossings*.

**2.3.4. StA en Problemas de Knot Localisation.** Este problema busca determinar el *knotted arc* más corto alrededor de la curva o, particularmente, el contorno de un polímero. Es especialmente relevante para encontrar nudos en polímeros, DNA y proteínas.

Para abordar este problema, se utilizó una red neuronal recurrente (para poder aprender datos secuenciales) entrenada con  $\omega_{StA}$ . La capa de salida se conforma por 100 neuronas, cada una representando la probabilidad de que dicho segmento de la curva forme parte del *knotted arc*. Se obtuvo una exactitud del 93 % (utilizando *binary cross-entropy* como métrica).

### 3. CONCLUSIÓN

Los resultados indican que tanto  $\omega_{StA}$  como  $\omega_{StS}$  pueden ser predictores muy poderosos para clasificar y localizar nudos, pues caracterizan su topología subyacente únicamente a partir de su información geométrica.

Entiendo que, más que explicar formalmente cómo es que el *local writhe* codifica la topología de los nudos en patrones distinguibles entre sí, el objetivo del artículo es presentar esta característica junto a algunos resultados que no son exhaustivos o contundentes, pero sí una excelente carta de presentación para motivar a otros investigadores a utilizarlo. Aun así, me gustaría conocer hasta qué punto el *local writhe* es funcional; si su capacidad para identificar topologías

decae conforme sube la complejidad de los nudos, por ejemplo, y, de no ser así, entender con exactitud a qué se debe esta capacidad.

Sobre esto último, una hipótesis muy válida que mencionan los autores del artículo es que las redes neuronales entrenadas con esta característica podrían codificar numéricamente un invariante topológico, pues incluso redes neuronales "simples" son capaces de aprender los patrones y distinguir nudos que algunos *knot polynomials* no pueden. Sin lugar a dudas, un estudio formal de esta característica podría revelar información útil para el desarrollo de nuevos invariantes y para descubrir posibilidades y limitaciones de esta técnica en particular.

**3.1. Sobre Escalabilidad.** Considero que los resultados presentados en el artículo son suficientes, al menos de forma preliminar, para mostrar que esta técnica es robusta. Sin embargo, pienso que hay algunas hipótesis adicionales que podrían ayudar a entender lo que ocurre al escalar este modelo.

Primero, vale la pena señalar que la representación StA como arreglo unidimensional contiene, en esencia, el mismo tipo de información que la representación StS como matriz cuadrada. Posiblemente, se puede

ver a StA como una "proyección" de StS a una sola dimensión a través de una función  $f : w_{StA} \rightarrow w_{StS}$ , parecida a una especie de media aritmética sobre un eje, dejando fijo el otro. En resumidas cuentas, existe una pérdida de información.

Esta pérdida no resulta significativa al probar el modelo con nudos simples, pero al ir creciendo en complejidad se vuelve cada vez más evidente, como puede notarse en la Figura 1-G. Aunque el patrón en StA es muy parecido, el patrón en StS es notablemente distinto. Un problema similar podría surgir para StS cuando la complejidad de los casos escale mucho. Una solución que extienda un poco más el margen en el que está técnica es eficaz, sería utilizar mas *beads* para modelar los nudos, pues esto permitiría tener mayor detalle de los patrones formados. Otra posibilidad, señalada por los autores como una limitación, es utilizar un writhe que considere el enredo entre más de un par de segmentos a la vez. Esto sigue siendo un campo de investigación activo.

Por lo pronto, me parece que la técnica descrita en este artículo puede cubrir con suficiencia las aplicaciones del problema de clasificación de nudos y de *knot localisation* en pliegues de proteínas, DNA, entre otros, como sugieren los autores.

#### 4. REFERENCIAS

- Sleiman, J. L., Burton, R. H., Caraglio, M., Gutierrez Fosado, Y. A., & Michieletto, D. (2022). Geometric Predictors of Knotted and Linked Arcs. *ACS Polymers Au*, 2(5), 341-350.
- Sleiman, J. L., Conforto, F., Fosado, Y. A. G., & Michieletto, D. (2024). Geometric learning of knot topology. *Soft Matter*, 20(1), 71-78.
- Van de Griend, P. (1996). A history of topological knot theory. *History and Science of Knots*, 205-260.
- Vandans, O., Yang, K., Wu, Z., & Dai, L. (2020). Identifying knot types of polymer conformations by machine learning. *Physical Review E*, 101(2), 022502.